

Projet de Maintenance Prédictive

Analyse de données capteurs et Machine Learning

DUARTE DOS SANTOS Samuel

01/09/2025

Contexte

La maintenance prédictive vise à anticiper les pannes avant qu'elles ne surviennent. Ce projet illustre cette approche sur des moteurs simulés (dataset NASA CMAPSS), en exploitant des séries temporelles issues de capteurs.

Données

- Données capteurs : température, pression, vibrations...
- Train / Test + Remaining Useful Life (RUL)

Méthodes

- **RandomForest** : baseline simple pour prédire la RUL
- **RandomForest amélioré** : normalisation et features glissantes
- **LSTM (Long Short Term Memory)** : modèle séquentiel pour exploiter la dynamique temporelle

Résultats

Modèle	RMSE	MAE
RandomForest baseline	~ 46	~ 35
RandomForest amélioré	~ 47	~ 35
LSTM amélioré	~ 34	~ 24

- **RMSE (Root Mean Squared Error)** : mesure l'écart quadratique moyen entre les valeurs prédites et les valeurs réelles. Il pénalise davantage les grosses erreurs et donne une idée de la précision globale du modèle.
- **MAE (Mean Absolute Error)** : correspond à l'erreur absolue moyenne entre les prédictions et les valeurs réelles. Plus facile à interpréter, il indique en moyenne de combien de cycles le modèle se trompe dans ses prédictions de RUL.

Visualisations

Résultats - RandomForest

La première approche utilise un RandomForest sur les capteurs bruts. Le nuage de points (Fig. 1) compare la RUL prédite à la RUL réelle. On observe une tendance correcte, mais les prédictions saturent pour les grandes valeurs de RUL.

La Fig. 2 illustre le suivi d'un moteur (unit 1). On note un fort bruit dans la prédiction, avec une surestimation persistante.




Figure 1: Nuage de points – RUL prédite vs RUL réelle (RandomForest, ensemble des moteurs)




Figure 2: Suivi temporel – Moteur 1 : RUL réelle vs RUL prédite (RandomForest)

RandomForest amélioré

Une variante avec normalisation et features glissantes a été testée. Les résultats restent comparables en termes de métriques globales, mais la stabilité des courbes s'améliore légèrement. Les mêmes visualisations ont été produites (scatter plot et suivi moteur).




Figure 3: Nuage de points – RUL prédite vs RUL réelle (RandomForest, ensemble des moteurs)




Figure 4: Suivi temporel – Moteur 1 : RUL réelle vs RUL prédite (RandomForest)

LSTM : Long short term memory

Les réseaux de neurones **LSTM (Long Short-Term Memory)** sont une architecture de *Recurrent Neural Networks (RNN)* spécialement conçue pour le traitement des données séquentielles.

Cette propriété rend les LSTM particulièrement adaptés à la **modélisation des séries temporelles**, comme les signaux de capteurs dans un contexte industriel.

Dans notre cas, ils apprennent à capturer la **dynamique d'évolution des moteurs** et permettent de prédire la **Remaining Useful Life (RUL)** en tenant compte de l'historique des mesures, plutôt qu'à partir de valeurs instantanées uniquement.




Figure 5: Nuage de points – RUL prédite vs RUL réelle (LSTM amélioré, ensemble des moteurs)




Figure 6: Suivi temporel – Moteur 1 : RUL réelle vs RUL prédite (RandomForest)

Le modèle **LSTM amélioré** obtient une erreur moyenne de **MAE = 25 cycles** (RMSE = 35, $R^2 = 0.55$). On observe que :

- Les prédictions sont **précises pour des RUL faibles** (pannes proches), ce qui est essentiel en maintenance prédictive.
- Pour des RUL intermédiaires, la dispersion autour de la diagonale augmente, traduisant une plus forte incertitude.
- Pour des RUL élevées, le modèle a tendance à **surestimer la durée de vie restante**, ce qui reflète une difficulté à extrapoler sur des moteurs encore jeunes.

Discussion

Les modèles séquentiels (LSTM) permettent de réduire l'erreur moyenne d'environ 35 à 24 cycles. Ils captent mieux la dégradation progressive, au prix d'une complexité plus élevée.

Conclusion

L'objectif de ce projet n'était pas d'obtenir le modèle le plus précis, mais de démontrer ma capacité à mettre en œuvre une démarche complète de data science appliquée à un cas concret de maintenance prédictive. Il illustre ainsi un cycle complet : préparation de données capteurs, modélisation prédictive et restitution des résultats.